데이터 분석 로직

데이터 분석 로직

1. 데이터 전처리
   a. 중복 제거 및 NaN 처리
   b. 클렌징
      html/url/이메일/멘션 제거
      해시태그는 #만 제거하고 단어는 살림
      반복 문자는 한 문자로 처리 (ex. !!!!!!!!!! → !)
      반복 초성 처리 (ex. ㅋㅋㅋㅋㅋ -> ㅋㅋ) → 문자열로 embedding하는 경우는 여기까지만
      이모지, 특수문자 등 감정 나타내는 경우 보존
      숫자 뒤 한글이 같이 붙어 있을지 제거X (ex.3만원)
      의미 없는 자음 모음 제거 (ex. ㄱㄱ)
      공백 제거
   c. 모델 이용한 광고 제거 : blockenters/sms-spam-classifier
   d. 토큰화
      일반명사, 고유명사, 동사, 형용사만 남기고 제거
   e. 필터링/stopwords/철자 수정
      줄임말/오타/ 구어체 치환
      기본 불용어 제거
      구어체 불용어 제거
      반응 표현제거
      의미 약한 일반 용언 제거
   f. stemming
      과거형 미래형 전부 맞추기 (ex.즐겼다 → 즐기다)

2. 데이터 벡터화, 임베딩
   - Doc2Vec → 토큰화 : 0.5501
   - Ko-SBERT → 문자열 : 0.1961
   - intfloat/e5-large-v2 → 문자열 : 0.6413
   - nlpai-lab/KURE-v1 → 문자열 : 0.4771
   - BAAI/bge-m3 → 문자열 : 0.1759
   - thenlper/gte-small → 문자열 : 0.5083

3. 덴드로그램과 UMAP을 사용한 시각화를 통해 최적의 임베딩 기법 선정 → E5
   - UMAP
   - 덴드로그램
   - PCA
   - t-SNE

4. HDBSCAN으로 클러스터 생성 후 노이즈 값 제거
   → ward 등 다른 방식으로도 평가하고 비교해볼 필요성이 있음.
   → optuna로 UMAP, HDBSCAN에서 DBCV 지수가 가장 높은 최적 파라미터 자동 탐색
   → 6개가 클러스터링 값으로는 최적

→ 결측값 제거.

5. E5는 문자열 임베딩 기법으로 이를 토큰화 진행
   → 바이그램과 유니그램 꼭 둘 다 적용해서 토큰화 진행할 것.

6. c-TF-IDF(액터)
   → cluster별 문서 결합 → 6개
   → CountVectorizer (n-gram 적용)
   → c-TF-IDF
   → Actor 키워드

7. LDA(액션)